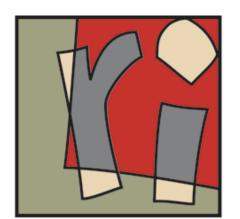
### Introduction au Parallèlisme Session 1 - Historique, Modèle et Architecture



Joel Falcou

LRI - Universite Paris Sud XI - CNRS

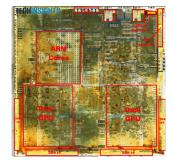
February 4, 2014



# Pourquoi un cours sur le parallélisme ?

Parce qu'il est partout du super-calculateur à votre tablette.







# Pourquoi un cours sur le parallélisme ?

#### Quels besoins?

- Résoudre des problèmes plus rapidement
  - Traiter plus dans un temps fini.
  - □ Réduire le temps de traitement pour un travail donné.
- Obtenir des meilleurs résultats dans le même temps
  - Modèles plus précis
  - Modèles plus complexes
- Traiter des problèmes de plus grande taille
  - Données des réseaux sociaux
  - Google
  - LHC



### Une introduction frileuse

- "I think there is a world market for maybe five computers."
  - Thomas Watson, chairman of IBM, 1943.



### Une introduction frileuse

- "I think there is a world market for maybe five computers."
  - Thomas Watson, chairman of IBM, 1943.
- "There is no reason for any individual to have a computer in their home."
  - Ken Olson, president and founder of Digital Equipment Corporation, 1977.



### Une introduction frileuse

- "I think there is a world market for maybe five computers."
  - Thomas Watson, chairman of IBM, 1943.
- "There is no reason for any individual to have a computer in their home."
  - Ken Olson, president and founder of Digital Equipment Corporation, 1977.
- On several recent occasions, I have been asked whether parallel computing will soon be relegated to the trash heap reserved for promising technologies that never quite make it."
  - Ken Kennedy, CRPC Directory, 1994.



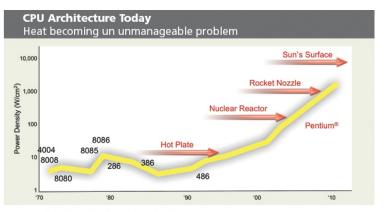
# Limite technologique

### Accélérons donc les processeurs!

- Soit une machine séquentielle à 1 Tflop
  - □ Les données doivent aller de la mémoire au CPU (distance r)
  - $\square$  Pour récupérer une donnée par cycle ( $10^{12}$  fois par seconde) à la vitesse de la lumière (c = 299 792 458 m/s = 3e8 m/s)
  - Donc  $r = c/10^{12} = .3 mm$
- Il faut mettre 1 Tera-octet de données dans 0.3 mm2
- Chaque mot occupe  $\approx$  3 Angstroms<sup>2</sup>, soit la taille d'un petit atome
- Attention aussi à la chaleur dégagée par un tel processeur !



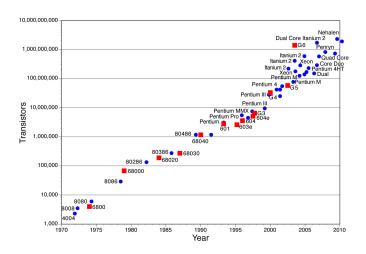
# Limite technologique



**Figure 1.** In CPU architecture today, heat is becoming an unmanageable problem. (Courtesy of Pat Gelsinger, Intel Developer Forum, Spring 2004)

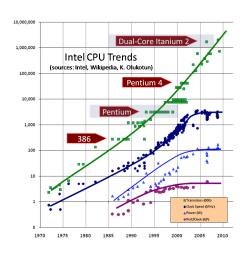


### Limite technologique





### The Free Lunch is Over





# Conséquences

- Le seul moyen d'augmenter les performances est l'augmentation du nombre d'unité de traitement travaillant en parallèle
- L'argument du coût des transferts des données tient toujours!
- Difficulté de la programmation de ces machines



### Plan

Introduction

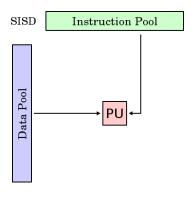
Classifications du Parallèlisme

Métriques

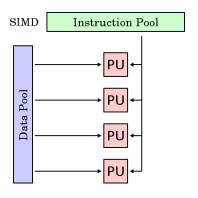


	Single Data	Multiple Data
Single Instruction	SISD typical thread	SIMD vector processors GPUs SSE instructions
Multiple Instruction	MISD rare possibly set of filters	MIMD cluster of computers

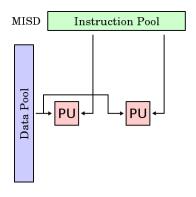




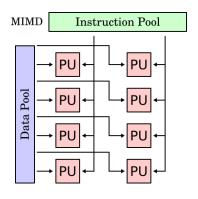














### Type de parallèlisme

### Objectifs du parallèlisme

- Pouvoir accélérer une application en
  - □ Divisant cette applications en sous-tâches
  - □ Exécuter ces sous-tâches en parallèles sur des unités différentes
- Il faut donc:
  - □ Trouver le parallélisme dans l'application
  - □ Trouver le bon grain de calcul/échange de données
  - Avoir des connaissances pour concevoir une solution efficace sur la machine cible



### Le parallélisme par l'exemple

#### Etre attentif!

- Pour avoir une application parallèle, il faut que l'application soit décomposable en sous-problèmes suffisamment indépendants
- Il faut pouvoir organiser le travail à répartir.
- Surcoût dû à la répartition du travail
- Trouver le meilleur algorithme parallèle
- Pas forcement celui qui est le plus efficace en séquentiel !



# Qu'espère-t-on?

#### Une grosse accélération

Idéalement, on espère avoir une accélération de P sur P processeurs!

#### En général ...

- Malheureusement, c'est rarement le cas
  - Parties séquentielles d'un algorithme
  - Problèmes de surcoût dus à des calculs redonnants, les coûts de transfert de données
- Parfois le gain est superieur à P
  - □ Différences de vitesse mémoire (mémoire vive vs caches)
  - Moins de calcul grâce au parallélisme (recherche dans des arbres)
  - Applications pour lesquelles l'exécution sur un processeur est impossible



# Type de parallèlisme

#### Le parallèlisme gratuit

- Parallélisme au niveau du bit (BLP, Bit Level Parallelism)
- Parallélisme d'instructions (ILP, Instruction Level Parallelism)
  - Exécuter plusieurs instructions par cycle d'horloge
    - Super-scalar, VLIW, EPIC
- Parallélisme au niveau du système

#### Limitations

- Niveau d'intelligence des processeurs et des compilateurs
- Complexité des applications
- Nombre d'éléments en parallèle



# Type de parallèlisme

### Par type d'interaction

- Mémoire partagée
- Passage de message

### Par type de décomposition

- Parallélisme de tâche
- Parallélisme de donnée



# Modèle de programmation

### Mémoire partagée

- Chaque processus interagit de manière asynchrone avec un banc mémoire globalement accessible
- Gestion manuelle des verrous (mutex, sémaphores, etc...)

#### Mise en oeuvre

- pthread
- OpenMP



# Mémoire partagée

### OpenMP

Version séquentielle

```
for(int i=0;i<size;++i)
out[i] = (a[i] +b[i])*0.5;</pre>
```

Version paralléle

```
#pragma omp for
for(int i=0;i<size;++i)
out[i] = (a[i] +b[i])*0.5;</pre>
```



# Modèle de programmation

### Passage de Message

- Chaque processus interagit avec les autres via l'envoi de message contenant des données.
- Communications point à poitn ou collectives
- Difficulté : Ou sont les données ?

#### Mise en oeuvre

- MPI
- Charm++



### Passage de Message

#### **MPI**

Version paralléle



# Métriques utiles

### Objectifs

- Mesurer la qualité d'un code paralléle
- Savoir repérer les problèmes
- Comaprer des implantations

### Types de métriques

- Métrique d'évaluation
- Métrique de diagnostique



### Accélération

#### Définition

$$\Gamma_p = \frac{T_1}{T_p}$$

#### avec:

■ **p** : nombre d'éléments de calcul

■ *T*<sub>1</sub> : temps d'exécution séquentiel

■ T<sub>p</sub> : temps d'exécution paralléle





#### Définition

$$E_p = \frac{\Gamma_p}{p} = \frac{T_1}{pT_p}$$

avec:

■ **p** : nombre d'éléments de calcul

lacksquare  $\Gamma_p$ : accélération idéale pour p éléments de calcul

■ T<sub>1</sub> : temps d'exécution séquentiel

■ T<sub>p</sub> : temps d'exécution paralléle

#### Loi d'Amdahl

#### Définition

- Soit:
  - $p \in \mathbb{N}$ , le nombre d'éléments de calcul

  - □ *T* (*p*) le temps d'exécution parallèle définie comme:

$$T(p) = T(1)\left(f + \frac{1}{p}(1-f)\right)$$

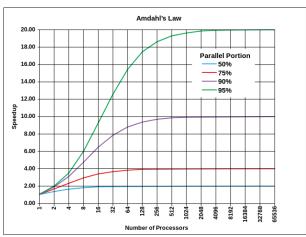
Alors:

$$\Gamma(p) = \frac{T(1)}{T(p)} = \frac{T(1)}{T(1)\left(f + \frac{1}{p}(1-f)\right)} = \frac{1}{f + \frac{1}{p}(1-f)}$$



### Loi d'Amdahl

$$\lim_{p\to\infty}\Gamma(p)=\frac{1}{f}$$





### Loi de Gustafson-Barsis

#### **Définition**

$$\Gamma(p) = f + p \cdot (1 - f)$$

